



ML 기초 세션 토이프로젝트_최종 발표

링커리어 대외활동 공고 크롤링 기반 '숨은 꿀공고' 탐지 -조회수·스크랩 전환율 잔차 분석을 통한 저평가 공고 발굴-

5조 | 박찬형 | 김은아 민승주 박재현 송상혁 왕희락

Contents

- 01 프로젝트 개요**
주제 선정 배경 · 문제의식 · 목표 · 라벨 타당성
- 02 데이터 수집**
크롤링 방법 및 데이터 구성
- 03 데이터 전처리**
데이터 정제 및 피처 구성
- 04 모델링**
Target A·B 구성 및 모델 성능 비교
- 05 결과 및 분석**
잔차 분류 · 신뢰도 필터링 · 군집화 · SHAP · 사례 분석
- 06 한계 및 결론**
분석의 한계 및 최종 결론

01. 프로젝트 개요

수많은 대외활동 공고, 어떤 공고가 정말 참여할 가치가 있을까?

대외활동의 중요성과 관심은 높아지고 있지만, 공고만으로 실질적인 가치를 판단하기는 어렵습니다.

로톡뉴스

'서포터즈'라는 이름의 청년 착취...수백 대 1 뚫고 들어갔더니 "짐꾼 신세"

2026. 01. 05 15:14 작성

손수형 기자
sh.son@lawtalknews.co.kr

활동 완료 후에도 약속된 보상이 이행되지 않은 사례

대기업 서포터즈 지원한 취준생 "마케팅 배운다더니 짐만 날랐다" 노무사 "기업이 의도한 사각지대...법 보호 전혀 못 받아"

자유이야기방 (익명)

여러분이 다 아실만한곳에서 한 대외활동을 사기당한것 같습니다

익명 2025.09.30 23:57 조회 636 추천 0 스크랩 0

<https://community.linkcareer.com/jeyou/4920694> 주소복사

7월달에 활동을 수료했는데 수료증을 아직도 받지 못했습니다.

카톡 방에서 담당자분과 두달간 4~5차례 소통했지만 다시 보내드리겠다 이런 비슷한 말밖에 없었습니다

완수인것 같다는 생각이 듭니다. 정말 어이가 없는데 이런경우는 그냥 계속 전락하는법밖에 없나요?

공개하고싶은데 법 걸릴까봐 못하겠네요

안내된 활동과 실제 활동 간 차이 발생

1 대외활동을 둘러싼 높은 관심과 경쟁



대외활동에 대한 관심 지속

- 대학생 커뮤니티에서 공고 정보와 지원 팁이 꾸준히 공유



취업 스펙 경쟁 심화

- 신입 채용에서도 인턴 경험 등이 중요해지며 스펙 경쟁 심화

2 그러나, 선택을 위한 정보는 부족


지원자는 공고에 제시된 정보만으로 실제 참여 가치와 조건 대비 경쟁 수준을 판단하기 어렵다.

조건 대비 경쟁이 낮고, 실제로 참여할 만한 공고를 사전에 찾을 수 있을까?

조회수와 스크랩 전환율의 잔차로 '숨은 꿀광고'를 탐지합니다

노출과 실제 관심을 각각 예측하고, 두 지표의 '예측 대비 차이'를 교차하여 광고를 분류합니다.

1 두 지표를 각각 예측



2 각 모델의 잔차 계산

$$\text{잔차} = \text{실제값} - \text{예측값}$$

광고 조건을 고려했을 때 예상했던 수준보다
실제 성과가 얼마나 높거나 낮았는지 확인

3 두 잔차를 교차

조회수 잔차 × 스크랩 전환율 잔차를 기준으로
전체 광고를 4가지 유형으로 분류

잔차 기반 광고 유형 분류



조건만으로 기대되는 성과와 실제 성과의 차이를 이용해, 상대적으로 저평가된 광고를 찾아냅니다.

'스크랩'은 실제 관심을 나타내는 지표로 볼 수 있을까?


직접적인 선행 연구가 없어, '저장 행동'과 실제 행동 간 관계를 인접 도메인에서 확인했습니다.

1 이커머스

저장 행동은 조회보다 강한 구매 의도 신호

약 **10배**

위시리스트(저장)는 단순 조회와 구분되는
명시적(explicit) 관심 신호로 활용



출처: "Purchase Intent: How to Capture and Convert It" — getswym.com

2 채용 공고 플랫폼

공고 저장은 실제 지원 행동으로 연결

68%

대외활동 공고와 구조적으로 가장 유사한
채용 공고 도메인의 직접 사례



Your Saved Jobs List Is a Mess

Most advice on this topic is too shallow. It acts like the hard part is spotting the right tab. It isn't. The hard part is keeping a saved list useful after you've stuffed it with roles you meant to revisit "later."

That's why so many professionals lose momentum. Approximately 75% of job seekers use the Save feature, and 68% of users who save at least three jobs apply to one within two weeks according to StoryCV's breakdown of LinkedIn saved jobs behavior. The feature matters. The mess you create with it matters too.

출처: "How to Find Saved Jobs on LinkedIn (and What to Do Next)" — StoryCV

저장 행동은 단순 조회보다 실제 행동 의향을 강하게 반영하는 신호로 볼 수 있습니다.

→ 이에 따라 본 프로젝트에서는 '조회 대비 스크랩 전환율'을 실제 관심도를 나타내는 지표로 활용합니다.

데이터 기반으로 '숨은 꿀광고'를 탐지하고, 그 특징을 분석합니다

예측 → 분류 → 분석 → 결과 도출의 과정을 통해 조건 대비 저평가된 대외활동 공고를 탐색합니다.

01

예측 모델 구축

조회수 · 스크랩
전환율 예측

Target A



조회수

Target B



스크랩 전환율

| 광고 조건을 기반으로
두 지표의 기대 수준 예측

02

광고 유형 분류

잔차 기반
4가지 유형 분류

숨은
꿀광고이미 유명한
좋은 광고그냥
별로인 광고낡시성
광고

| 두 모델의 잔차를 교차하여
광고 유형 구분

03

특성 분석

군집화 · SHAP 분석



| 저평가 광고 그룹의
하위 특성 및 영향 요인 분석

04

최종 결과

숨은 꿀광고 및 특징 제시



| 조건 대비 저평가된
대외활동 공고 목록 + 주요 특징

단순히 인기 있는 광고가 아닌, 광고 조건을 고려했을 때 상대적으로 저평가된 공고를 발굴하는 것이 프로젝트의 핵심 목표입니다.

02. 데이터 수집

링크리어의 마감 대외활동 공고를 수집했습니다

조회수·스크랩수가 안정화된 공고를 확보하기 위해, 과거 마감 공고를 대상으로 Selenium 기반 동적 크롤링을 진행했습니다.

데이터 수집 대상

공고달력

<

2026.09

>

오늘

공고 달력

내 스크랩 달력

대외활동

공모전

동아리

인턴

채용

활동분야

관심분야

활동매체

활동기간

모임지역

주최기관

상세필터를 선택해 관심있는 공고를 쉽게 찾아보세요.

선택한 조건으로 검색

월간

주간

모두

시작

마감

공고 제목, 기업명 검색

링크리어는 대외활동 공고를 월별 달력 형태로 제공하며,
마감된 공고에는 '마감' 표시가 부여됩니다.

01

수집 출처
링크리어
대외활동 공고

대외활동·공모전 정보 플랫폼

02

수집 방식
Selenium 기반
동적 크롤링

브라우저 렌더링을 활용해 공고 정보 수집

03

수집 범위
접수 마감일 기준
최근 12개월

최근 1개월 이내 마감 공고 제외

단순히 인기 있는 공고가 아닌, 공고 조건을 고려했을 때 상대적으로 저평가된 공고를 발굴하는 것이 프로젝트의 핵심 목표입니다.

2단계 크롤링을 통해 공고 URL과 상세 정보를 수집했습니다

공고 달력에서 마감 공고의 URL을 먼저 확보한 뒤, 각 상세페이지를 순회하며 구조화된 필드를 파싱했습니다.

1 공고 달력

월 단위로 과거 달력 이동
→ 날짜 칸 클릭

공고달력

< 2026.09 > 오늘

공고 달력

대외활동 공모전 동아리 인턴 채용

활동분야 관심분야 활동혜택 활동기간 모집지역 주최기관

상세필드를 선택해 관심있는 공고를 쉽게 찾아보세요.

선택한 조건으로 검색

월간 주간

모든 시작 마감 공고 제목, 기업명 검색

월	월	화	수	목	금	토
30	31	01	02	03	04	05
마감 [영남모집] 11주...	마감 [부산시] 시민...	마감 <2026 청년문화주...	마감 [상남시] GWG 2026...	마감 [상남시] GWG 2026...	마감 [상남시] GWG 2026...	마감 [상남시] GWG 2026...
마감 [영남모집] 11주...	마감 [부산시] 시민...	마감 [상남시] GWG 2026...	마감 [상남시] GWG 2026...	마감 [상남시] GWG 2026...	마감 [상남시] GWG 2026...	마감 [상남시] GWG 2026...
마감 [영남모집] 11주...	마감 [부산시] 시민...	마감 [상남시] GWG 2026...	마감 [상남시] GWG 2026...	마감 [상남시] GWG 2026...	마감 [상남시] GWG 2026...	마감 [상남시] GWG 2026...
마감 [영남모집] 11주...	마감 [부산시] 시민...	마감 [상남시] GWG 2026...	마감 [상남시] GWG 2026...	마감 [상남시] GWG 2026...	마감 [상남시] GWG 2026...	마감 [상남시] GWG 2026...
마감 [영남모집] 11주...	마감 [부산시] 시민...	마감 [상남시] GWG 2026...	마감 [상남시] GWG 2026...	마감 [상남시] GWG 2026...	마감 [상남시] GWG 2026...	마감 [상남시] GWG 2026...

2 일자별 공고 목록

팝업에서 '마감' 표시가 있는 공
고의 상세페이지 URL만 선별

< 2026.09.01 (화) >

마감	대외활동	주식회사 투아라이브	유럽 여행하면서 혜택까지 받을 ...	08/10 ~ 09/01	🔖
마감	대외활동	한국토지주택공사 글로벌 협력센터	「제7회 LH 글로벌 비즈니스 컨...	08/17 ~ 09/01	🔖
마감	대외활동	한국대학생인재협회	문과생이러면 주목! 11주 만에 ...	08/20 ~ 09/01	🔖
마감	대외활동	한국대학생인재협회	[학기별행 기능] 주말에 끝내는 ...	08/20 ~ 09/01	🔖
마감	대외활동	한국대학생인재협회	[영남모집] 나한테 맞는 직무, 아...	08/20 ~ 09/01	🔖
마감	대외활동	성모지역복지관	세자물 지역 축제 봉사자 모집	08/21 ~ 09/01	🔖
마감	대외활동	한국대학생인재협회	[영남모집] 11주간 현직자와 함...	08/21 ~ 09/01	🔖
마감	대외활동	한국대학생인재협회	[올해 마지막] 대항해 열정 사...	08/21 ~ 09/01	🔖

3 공고 상세페이지

「제7회 LH 글로벌 비즈니스 컨벤션」 개최 안내

한국토지주택공사 글로벌협력센터

기업형태: 공공기관/공기업

참여대상: 대상 제한 없음

접수기간: 시작일 2026.08.17, 마감일 2026.09.01

활동기간: 26.9 ~ 26.9

모집인원: 00명

활동지역: 부산 해운대구

우대역량: 외국어

활동혜택: 사은품 지급, 행사 참여

관심분야: 행사/페스티벌, 기타

원동분야: 강연

추가혜택: 학기드로우

공유하기: f x n g y

홈페이지 지원

스크랩한 사용자 확대보기 (14명)

관심 유지 통계 보기

1단계에서 확보한 URL을 순회하며
상세페이지의 구조화된 필드 파싱

조회수 · 스크랩수 · 기업형태 · 참여대상 · 접수기간
· 모집인원 · 활동지역 · 활동혜택 등

URL 수집과 상세정보 수집을 분리한 2단계 구조로 데이터를 확보했습니다.

총 7,437건의 공고에서 16개 필드를 수집했습니다

공고 상세페이지에서 분석에 필요한 기본 정보부터 모집 조건·활동 정보까지 구조화된 데이터를 확보했습니다.

수집 필드 목록 (상세페이지 기준 16개)

1 기본 정보

title	제목
views	조회수
scrap_count	스크랩수
organization	기관명

2 모집 정보

company_type	기업형태
target	참여대상
recruit_count	모집인원
activity_region	활동지역

3 기간 정보

recruit_start	접수 시작일
recruit_end	접수 마감일
activity_period	활동기간

4 활동 특성

preferred	우대역량
benefit	활동혜택
extra_benefit	추가혜택
interest_field	관심분야
activity_field	활동분야

크롤링 결과 데이터셋

	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O	P	Q	R	S
	url	activity_id	title	views	scrap_count	organization	company_type	target	recruit_start	recruit_end	activity_period	preferred	benefit	extra_benefit	interest_field	activity_field			
1	https://www.khoda.co.kr	240777	국제이벤트	1217	50	국제이벤트비행단	대형	제한	2025.05.01	2025.07.11	25.5 ~ 25.00명	지역	제한	파워볼로고수등 및 카팅 또는	항공/제기/세로타츠, 마케터				
2	https://www.khoda.co.kr	240820	10월이 니	252	1	한국에드	중소기업	청소년	2025.06.01	2025.07.11	25.6 ~ 25.6명	지역	제한	취업/인턴/봉사 참여	문화/역사, 기자단				
3	https://www.khoda.co.kr	243129	70일이 니	349	0	한국에드	중소기업	청소년	2025.05.21	2025.07.11	25.6 ~ 25.50명	지역	제한	취업/인턴/봉사 참여	문화/역사, 기자단				
4	https://www.khoda.co.kr	245866	국제이벤트	1009	40	국제이벤트비행단	대형	제한	2025.06.01	2025.07.11	25.6 ~ 25.00명	지역	제한	파워볼로고수등 및 카팅 또는	항공/제기/세로타츠, 마케터				
5	https://www.khoda.co.kr	240050	2025 대구	271	2	(주)클라인 카타	대학생, 직	대학생, 직	2025.06.11	2025.07.11	25.7 ~ 25.30명	대구	카타	심무 교육	교육, 카타, 멘토링, 카타				
6	https://www.khoda.co.kr	251705	(스펙) 대학	19654	779	스펙이치	외국계기업	대학생	2025.07.01	2025.07.11	25.7 ~ 25.50명	지역	제한	문화/역사, 기자단	문화/역사, 기자단				
7	https://www.khoda.co.kr	251792	(56) 세로타츠	1505	36	(주)이디나	비영리단체	대학생	2025.06.11	2025.07.11	25.7 ~ 25.12	지역	제한	취업/인턴/봉사 참여	문화/역사, 기자단				
8	https://www.khoda.co.kr	251909	(한국) 탐구	3451	89	주식회사	중소기업	대학생	2025.06.31	2025.07.11	25.7 ~ 25.00명	지역	제한	파워볼로고수등 및 카팅 또는	항공/제기/세로타츠, 마케터				
9	https://www.khoda.co.kr	252474	스타, 제1	471	17	사회적협동조합	비영리단체	대학생	2025.06.31	2025.07.11	25.7 ~ 25.00명	지역	제한	취업/인턴/봉사 참여	문화/역사, 기자단				
10	https://www.khoda.co.kr	252874	[2025] 010	1284	20	주식회사	중소기업	대학생	2025.07.01	2025.07.11	25.7 ~ 25.00명	지역	제한	파워볼로고수등 및 카팅 또는	항공/제기/세로타츠, 마케터				
11	https://www.khoda.co.kr	250860	APEC 2025	4398	95	광안도	공공기관	대학생, 직	2025.06.21	2025.07.11	25.10 ~ 21.20명	지역	제한	카타	활동비, 분	행사/제기/세로타츠, 마케터			
12	https://www.khoda.co.kr	251549	서울시립노	222	2	시립노	문화공공기관	청소년	대	2025.06.21	2025.07.11	25.7 ~ 26.00명	지역	제한	문화/역사, 기자단	문화/역사, 기자단			
13	https://www.khoda.co.kr	253422	(통과) 피	283	7	통과	피/카타	대학생	2025.07.01	2025.07.11	25.7 ~ 25.8	지역	제한	카타	사은품 지급	문화/역사, 기자단			
14	https://www.khoda.co.kr	252113	(시립) 청소년	354	2	시립청소년비행단	비영리단체	청소년	대	2025.07.01	2025.07.11	25.7 ~ 25.6명	서울	카타	수료증 및	문화/역사, 기자단			
15	https://www.khoda.co.kr	252820	제3회 코	640	12	한국해상비행단	비영리단체	대학생, 직	2025.07.01	2025.07.11	25.7 ~ 25.00명	부산	외국어	수료증 및 유니폼	문화/역사, 기자단				
16	https://www.khoda.co.kr	242827	(주)진대	619	10	교육노	문화공공기관	대학생, 직	2025.07.01	2025.07.11	25.7 ~ 26.00명	서울	강남/카타	활동비, 분	문화/역사, 기자단				
17	https://www.khoda.co.kr	244049	(관악) 청년1	415	8	교육노	문화공공기관	대학생	2025.05.21	2025.07.11	25.7 ~ 25.00명	서울	관악/카타	활동비, 분	문화/역사, 기자단				
18	https://www.khoda.co.kr	240814	2025년 유	457	1	유성구의회	비영리단체	청소년	2025.05.11	2025.07.11	25.7 ~ 25.15명	대전	카타	수료증 및	문화/역사, 기자단, 봉사단/국내				

7,437건 × 16개 필드
원본 수집 데이터

수집된 원본 데이터 7,437건을 기반으로 이후 정제 및
피쳐 엔지니어링을 진행했습니다.

03. 데이터 전처리

9단계의 전처리를 통해 분석에 적합한 데이터로 정제했습니다

파생 피처를 최대한 다양하게 생성한 뒤, 정제·검증 과정을 거쳐 최종 피처셋을 구성했습니다.

- 0 파생 피처 생성 1 중복 제거 2 결측치 처리 3 범주형 정규화

0 다양한 파생 피처 생성

접수일자·활동기간 등 날짜 정보와 제목·혜택 텍스트를 기반으로 파생 피처 생성

최종 약 100개 기준

0단계 — 파생 피처 생성 (최종 100개 기준)

구분	개수	내용
날짜·기간 파생	8개	접수기간, 마감 요일·월, 활동기간(개월수) 등
텍스트 형태 파생	포함(위 8개 내)	제목 길이, 대괄호·느낌표·숫자 포함 여부, 혜택 개수 등
카테고리 평치기 (원핫인코딩)	약 40개	기업형태·참여대상·활동지역·모집시즌을 "해당함/해당안함"(1/0)으로 나눈 값
다중선택 평치기 (멀티라벨)	30개	관심분야(20개 키워드)·활동분야(10개 키워드)를 각 키워드별 포함 여부(1/0)로 나눈 값
기관 관련 파생	2개	같은 기관이 이전에 올린 공고들의 평균 조회수· 전환율을 계산해 만든 "기관 평판 점수"
글 내용 관련 파생	20개	제목·혜택·후대사항에 어떤 단어가 쓰였는지를 분석해, 비슷한 표현을 쓴 공고끼리 비슷한 값이 나오도록 20개의 숫자로 요약한 값

1 중복 제거

제목 + 주최기관 기준으로 중복 여부 확인

7,437건 → 중복 144건 제거

2 결측치 처리

- 필드 특성에 따라 결측 처리 방식을 다르게 적용
- 실제 결측과 '값이 없음' 자체가 의미를 갖는 경우를 구분해 명시적으로 라벨링

3 텍스트·범주형 정규화

- 표기 통일·회소 범주 통합·다중선택 필드 분리
- 표본이 적은 카테고리는 '기타'로 통합하고, 관심분야·활동분야는 키워드 단위로 정리


초기에는 피처를 폭넓게 생성하고, 이후 다중공선성·누수 검증을 통해 필요한 피처만 선별했습니다.

타겟 변수의 분포를 보정하고 이상치를 점검했습니다

조회수·스크랩수의 롱테일 분포를 완화하고, 비정상적인 관측치를 확인해 데이터 안정성을 확보했습니다.

4 타겟 변수 처리

롱테일 분포 보정 | 조회수·스크랩수에서 뚜렷한 롱테일 분포 확인



조회수 · 스크랩수 → log1p 변환

$\text{scrap_rate} = \text{scrap_count} / \text{views}$
조회 대비 실제 관심 행동의 비율

5 이상치 확인

극단값 ≠ 무조건 제거

| 극단값

조회수·스크랩수의 큰 값은 log1p 변환으로
우선 완화

| 비정상 관측치

명백한 오류·비정상 값에 한해 별도 제거
또는 수정

항목	규모	처리 방법
조회수/스크랩수 왜도	왜도 6.69 / 6.28	log1p 변환 (원본 후 왜도 0.81 / 0.19)
웹수기전 1년 초과	24건	통일 기준 반복 게시로 시작일이 오름된 것으로 판단, 제거
제목 100자 truncation	4건	크롤링 단계에서 텍스트가 잘려 감이 정보 왜곡, 제거
활동기간 "99.12" 오기	2건	2099년으로 오인식되었던 해당 오류, "무기한"으로 재분류

극단값을 일괄 제거하지 않고 분포 변환과 이상치 점검을 거쳐 데이터의 정보 손실을 최소화했습니다.

조회수의 노출 기간 차이를 통제하고, 다중공선성과 타겟 누수를 점검해 모델링에 사용할 피처를 선별했습니다.

[illegible]

04. 모델링

두 타겟별로 다양한 회귀 모델을 학습하고 성능을 비교했습니다

노출과 관심을 각각 예측하는 Target A·B에 대해 베이스라인부터 트리 기반 모델까지 성능을 비교했습니다.

1 Target A / B 구성

Target A
daily_views_log1p

광고 조건으로 일평균 조회수를 예측


Target B
scrap_rate %

광고 조건으로 스크랩 전환율을 예측

두 타겟의 예측값과 실제값의 차이(잔차)를 교차해 조건 대비 저평가된 '숨은 꿀광고'를 식별합니다.


2 모델 비교 | 베이스라인(선형회귀·Ridge)부터 트리 기반 모델(RandomForest·LightGBM)까지 비교하였습니다. 하이퍼파라미터는 고정된 탐색 범위 내에서 GridSearchCV로 탐색하였습니다.

Target A (조회수) 모델별 성능 비교



Target A


Target B (전환율) 모델별 성능 비교



Target B

LightGBM과 Ridge를 결합한 앙상블 블렌딩을 최종 모델로 채택했습니다

두 타겟 모두 단일 LightGBM보다 가중 평균 블렌딩이 근소하게 더 우수한 성능을 보였습니다.



$$\text{최종 예측값} = w \times \text{LightGBM 예측값} + (1-w) \times \text{Ridge 예측값}$$

| 타겟별 최종 파라미터

- Target A: LightGBM 78% + Ridge 22% → MAE 0.5256 / R² 0.6506
- Target B: LightGBM 84% + Ridge 16% → MAE 0.9355 / R² 0.4383

05. 결과 및 분석

5-fold 교차검증 기반 잔차를 이용해 공고를 4가지 유형으로 분류했습니다

조회수 잔차와 전환율 잔차를 교차하여 조건 대비 저평가된 '숨은 꿀공고'를 식별했습니다.

최종 확정된 앙상블 모델(LightGBM + Ridge)로 전체 7,264건의 예측값을 산출하고 실제값과의 차이(잔차)를 계산했습니다. 학습 데이터에 대한 재예측으로 잔차가 인위적으로 작아지는 것을 방지하기 위해, 5-fold 교차검증으로 모델이 학습에 사용하지 않은 데이터 기준의 예측값을 활용했습니다.

- X축: 조회수 잔차 (실제-예측, 로그스케일) — 노출부족(-) / 노출초과(+)
- Y축: 전환율 잔차 (실제-예측, %p) — 기대이하(-) / 기대초과(+)

기본 사분면 분류 결과 (전체 7,264건)

사분면	정의	건수	비중
숨은 꿀공고	노출부족 + 전환 기대초과	1,340건	18.4%
이미 유명한 좋은 공고	노출초과 + 전환 기대초과	2,139건	29.4%
그냥 별로인 공고	노출부족 + 전환 기대이하	2,441건	33.6%
낚시성 공고	노출초과 + 전환 기대이하	1,344건	18.5%



경계 부근의 불안정한 판정을 제외하기 위해 신뢰도 필터링을 적용했습니다


두 잔차 축의 경계선까지 거리를 기준으로 판정의 신뢰도를 4단계로 구분했습니다.

신뢰도 지표 정의

- 사분면의 0 경계 부근에 위치한 공고는 잔차 차이가 작아, 조건이 조금만 달라져도 분류 결과가 바뀔 수 있습니다.
- 그래서 두 축 중 경계에 더 가까운 거리를 기준으로 신뢰도를 정의했습니다.

$$\text{신뢰도 지표} = \min(|\text{조회수 잔차}|, |\text{전환율 잔차}|)$$

※ 값이 클수록 두 축 모두 경계에서 충분히 벗어나 있어 판정의 신뢰도가 높습니다.




‘설득력 있음’ 이상 숨은 콜공고 537건을 후속 분석 대상으로 선정

숨은 꿀공고의 특성을 파악하기 위해 군집화 분석을 진행했습니다

'설득력 있음' 이상 숨은 꿀공고 537건을 대상으로 원본 특성만을 활용해 군집 구조를 탐색했습니다.

| K-means 시도 - 실루엣 계수가 낮게 나타남

- 잔차·타겟 변수는 제외하고 접수기간, 제목 형태, 우대역량 개수 등 공고의 원본 피처만 사용
- $k = 2 \sim 9$ 구간 실루엣 계수 0.11 ~ 0.14



모든 공고를 강제로 군집에 편입하지 않고 이상치를 별도로 식별하는 DBSCAN에서 군집 구조가 개선되었습니다.

숨은 꿀공고의 특성을 파악하기 위해 군집화 분석을 진행했습니다


'설득력 있음' 이상 숨은 꿀공고 537건을 대상으로 원본 특성만을 활용해 군집 구조를 탐색했습니다.

DBSCAN 적용 — 실루엣 계수 개선

- 밀도 기반 군집화인 DBSCAN을 적용한 결과,
Silhouette Score 0.28
→ '의미 있는 구조' 기준 0.25 최초 충족

DBSCAN 군집화 결과 요약 (숨은 꿀공고 선피그림 537건, 실루엣 계수 0.28)



그룹	개수	특성
군집0	46건	노원포 100%, 침수기간 17일(물음), 우다해당 1.2배(적음) → "단기노원포"
군집1	474건 (88%)	침수기간 25일, 특장품0 → "포슬함" 대다수
노이즈 [-1]	27건	침수기간 110일(원본노원포로 신), 우다해당 1.9배(적음) → 진짜 피해자의 특이 사례



모든 공고를 강제로 군집에 편입하지 않고 이상치를 별도로 식별하는 DBSCAN에서 군집 구조가 개선되었습니다.

SHAP을 통해 조회수와 전환율에 영향을 미치는 주요 피처를 확인했습니다

잔차·군집화와 별개로, 회귀모델이 각 타겟을 예측할 때 어떤 피처를 주요 근거로 활용했는지 분석했습니다.



SHAP 그래프의 피처명 용어 설명

피처명	의미
org_target_enc_A	기관 평판 점수 (조회수 기준) 같은 기관이 과거에 올린 다른 광고들의 평균 조회수를 계산해 낸 값
org_target_enc_B	기관 평판 점수 (전환율 기준) 같은 기관이 과거에 올린 다른 광고들의 평균 스크린 전환율을 계산해 낸 값

- 접수기간과 기관 평판 점수 등이 주요 예측 피처로 나타났습니다.
- Target B에서는 텍스트 기반 파생 피처가 다수 상위권에 포함되었습니다.

SHAP은 '저평가의 원인'이 아니라, 일반적으로 어떤 피처가 조회수·전환율 예측에 영향을 주는지를 해석한 결과입니다.

높은 신뢰도의 '숨은 꿀공고'는 특정 기관 규모에 한정되지 않았습니다

'매우 설득력 있음'으로 분류된 상위 10% 공고 중 대표 사례를 확인해 실제 공고의 특성을 살펴봤습니다.

"매우 설득력 있는" 숨은 꿀공고 상위 사례

공고명	기관	조회수 증가	전환율 증가(%p)
러너블 웰린저스 3기 _러닝콘텐츠 기획...	러너블주식회사	-1.53	1.46
[광양시광양장애인복지관] 2026년 장애...	광양시광양장애인복지관 / 전국장애인재활협회	-2.00	1.39
비전 스켈커 브랜드 유아를 SNS 터프...	주식회사 와이디(YD)	-1.39	1.45
삼성생명 12월 금융 아카데미 멘토링	삼성생명	-1.42	1.37
2026년 해외일경험(WELL) 베트남 ...	글로벌위업선티	-1.55	1.26
2026 경남관광박람회 대학생서포터즈 1...	(주)케이앤씨	-1.26	1.55
전통 차례음식 살리기 프로젝트팀 모집	주식회사 메모리울	-1.20	1.32
[NH농협은행] 제3기 NH디지털패널 모...	NH농협은행	-1.14	2.18

소규모 스타트업부터 대기업·금융권까지 다양한 기관의 공고가 포함되어,
기관 인지도와 관계없이 개별 공고 단위의 저평가가 발생할 수 있음을 확인했습니다.

06. 한계 및 결론

'숨은 꿀공고'를 확정하는 것이 아닌, 저평가 가능성이 높은 후보를 탐색했습니다

잔차 기반 탐지의 가능성을 확인하는 동시에, 정형 데이터만으로 설명하기 어려운 한계도 확인했습니다.

1 한계점



Target B 예측력 한계

전환율 $R^2 = 0.44$ 로 조회수 $R^2 = 0.65$ 보다 낮음
개인 판단이 개입되는 스크랩 행동의 높은 변동성



사분면의 설득력 부족

크롤링 광고의 약 절반이 사분면 경계상에 위치
SNS 확산·개인 취향·노출 알고리즘 등 정형 데이터 외 요인 가능성



임계값 선택의 성격

신뢰도 등급은 통계적 유의성 검정이 아닌 표본 내 백분위 기반의 상대적 기준

2 분석 결과



모델링

LightGBM + Ridge 앙상블

Target A R^2 0.65 | Target B R^2 0.44



잔차 기반 분류

두 모델의 잔차를 교차해 4개 공고 유형 분류



군집화

K-means의 한계 확인 후 DBSCAN 적용
→ Silhouette Score 0.28



SHAP

접수기간·기관 평판·텍스트 표현 방식이 성과에 영향을 미치는 주요 요인으로 확인

본 프로젝트는 '어떤 공고가 저평가되었는지 확정적으로 판정하는 도구'가 아니라,
조건 대비 저평가되었을 가능성이 있는 후보를 통계적 근거와 함께 제시하는 탐색적 도구입니다.

Q&A

감사합니다

5조 | 박찬형 | 김은아 민승주 박재현 송상혁 왕희락